Nama: Raina Imtiyaz

NIM: 2502010976

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import time
sns.set()
```

from sklearn.linear_model import LogisticRegression
from sklearn.tree import DecisionTreeClassifier
from pandas.plotting import scatter_matrix

from sklearn.preprocessing import StandardScaler

from sklearn.model_selection import train_test_split, GridSearchCV

from sklearn.neighbors import KNeighborsClassifier

from sklearn.svm import SVC

 $from \ sklearn. ensemble \ import \ Voting Classifier, \ Ada Boost Classifier, \ Random Forest Classifier, \ Bagging Classifier \ and \ and \ Bagging Classifier \ and \ and$

from sklearn.metrics import confusion_matrix
from sklearn import metrics
from sklearn.metrics import classification_report
import warnings
warnings.filterwarnings('ignore')
%matplotlib inline

df = pd.read_csv("diabetes.csv", sep=',')

df.head()

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome	1
0	6	148	72	35	0	33.6	0.627	50	1	
1	1	85	66	29	0	26.6	0.351	31	0	
2	8	183	64	0	0	23.3	0.672	32	1	
3	1	89	66	23	94	28.1	0.167	21	0	
4	0	137	40	35	168	43.1	2.288	33	1	

df.tail()

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	${\tt DiabetesPedigreeFunction}$	Age	Outcome	0
763	10	101	76	48	180	32.9	0.171	63	0	
764	2	122	70	27	0	36.8	0.340	27	0	
765	5	121	72	23	112	26.2	0.245	30	0	
766	1	126	60	0	0	30.1	0.349	47	1	
767	1	93	70	31	0	30.4	0.315	23	0	

#iInformation about the dataset
df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 768 entries, 0 to 767
Data columns (total 9 columns):

Data	cordinis (cocar 3 cordinis)	•	
#	Column	Non-Null Count	Dtype
0	Pregnancies	768 non-null	int64
1	Glucose	768 non-null	int64
2	BloodPressure	768 non-null	int64
3	SkinThickness	768 non-null	int64
4	Insulin	768 non-null	int64
5	BMI	768 non-null	float64
6	DiabetesPedigreeFunction	768 non-null	float64
7	Age	768 non-null	int64
8	Outcome	768 non-null	int64

dtypes: float64(2), int64(7)
memory usage: 54.1 KB

#descriptive statistic
df.describe().T



#check null values
df.isnull().sum()

Pregnancies 0 Glucose 0 BloodPressure 0 SkinThickness 0 Insulin 0 BMI 0 DiabetesPedigreeFunction 0 Age 0 Outcome 0 dtype: int64

df_copy = df.copy(deep = True)

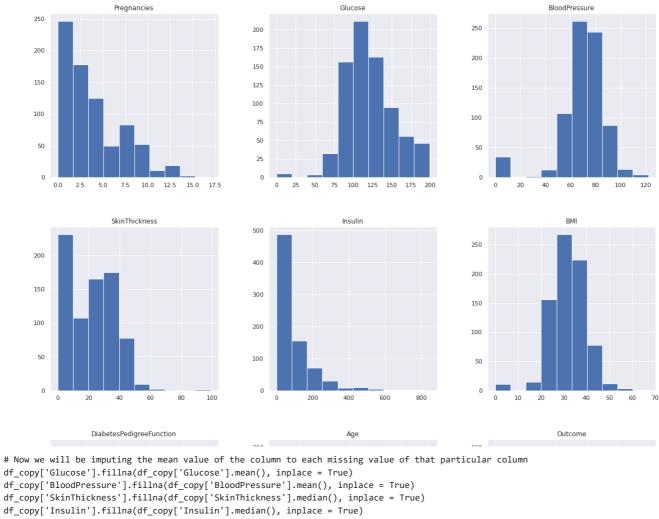
df_copy[['Glucose','BloodPressure','SkinThickness','Insulin','BMI']] = df_copy[['Glucose','BloodPressure','SkinThickness','Insulin','BMI']

Showing the Count of NANs
print(df_copy.isnull().sum())

0 Pregnancies Glucose 5 BloodPressure 35 SkinThickness 227 Insulin 374 BMI 11 ${\tt DiabetesPedigreeFunction}$ 0 Age 0 Outcome 0 dtype: int64

Plotting the data distribution plots before removing null values

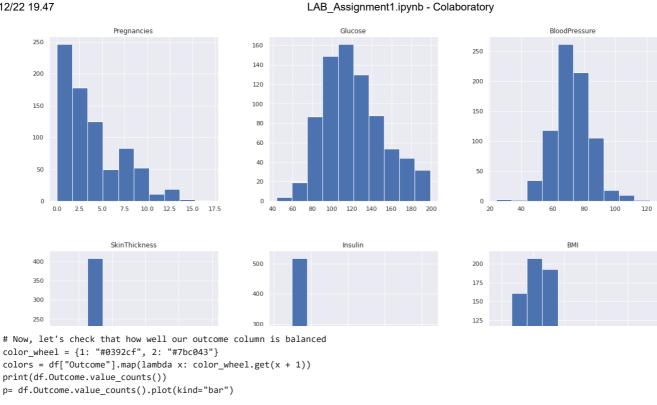
p = df.hist(figsize = (20,20))

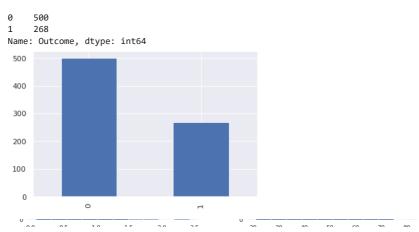


df_copy['BMI'].fillna(df_copy['BMI'].median(), inplace = True)

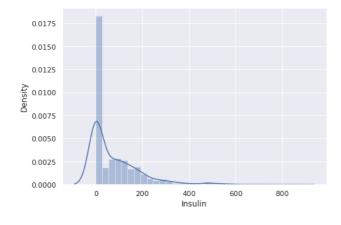
Plotting the distributions after removing the NAN values

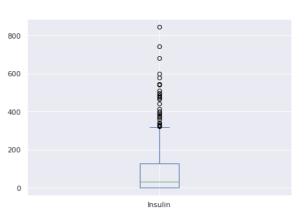
 $p = df_{copy.hist(figsize = (20,20))}$



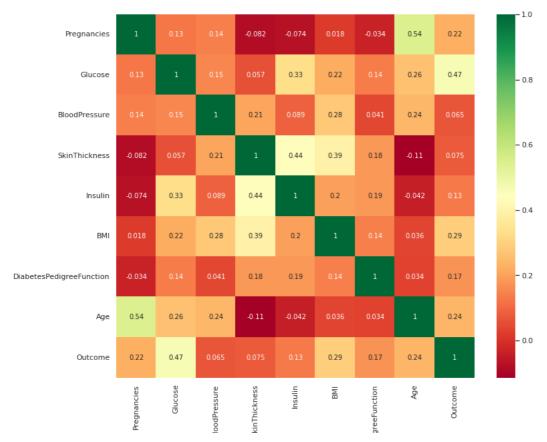


plt.subplot(121), sns.distplot(df['Insulin']) plt.subplot(122), df['Insulin'].plot.box(figsize=(16,5)) plt.show()





#Correlation plt.figure(figsize=(12,10)) $p = sns.heatmap(df.corr(), annot=True, cmap = 'RdY1Gn') \ \# \ seaborn \ has \ an \ easy \ method \ to \ showcase \ heatmap \ df.corr(), annote \ heatmap \ heatmap \ df.corr(), annote \ heatmap \$



df_copy.head()

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome	1
0	6	148.0	72.0	35.0	125.0	33.6	0.627	50	1	
1	1	85.0	66.0	29.0	125.0	26.6	0.351	31	0	
2	8	183.0	64.0	29.0	125.0	23.3	0.672	32	1	
3	1	89.0	66.0	23.0	94.0	28.1	0.167	21	0	
4	0	137.0	40.0	35.0	168.0	43.1	2.288	33	1	

sc_X = StandardScaler() #scaling hanya untuk dependant variable

X = pd.DataFrame(sc_X.fit_transform(df_copy.drop(["Outcome"],axis = 1),), columns=['Pregnancies', 'Glucose', 'BloodPressure', 'SkinThick
X.head()

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age
0	0.639947	0.865108	-0.033518	0.670643	-0.181541	0.166619	0.468492	1.425995
1	-0.844885	-1.206162	-0.529859	-0.012301	-0.181541	-0.852200	-0.365061	-0.190672
2	1.233880	2.015813	-0.695306	-0.012301	-0.181541	-1.332500	0.604397	-0.105584
3	-0.844885	-1.074652	-0.529859	-0.695245	-0.540642	-0.633881	-0.920763	-1.041549
4	-1.141852	0.503458	-2.680669	0.670643	0.316566	1.549303	5.484909	-0.020496

y = df_copy.Outcome
print(y)

767 0 Name: Outcome, Length: 768, dtype: int64

#Splitting the dataset

```
X = df.drop('Outcome', axis=1)
v = df['Outcome']
X_train, X_test, y_train, y_test = train_test_split(X,y, test_size=0.2, random_state=42)
#SVC Classifier
svc_model = SVC()
svc_model.fit(X_train, y_train)
     SVC()
svc_pred = svc_model.predict(X_test)
print(confusion_matrix(y_test, svc_pred))
print(classification_report(y_test, svc_pred))
     [[87 12]
      [24 31]]
                   precision
                                recall f1-score
                                                   support
                0
                                  0.88
                                                         99
                        0.78
                                             0.83
                        0.72
                                  0.56
                                                         55
                1
                                            0.63
         accuracy
                                             0.77
                                                        154
        macro avg
                        0.75
                                  0.72
                                             0.73
                                                        154
     weighted avg
                        0.76
                                  0.77
                                             0.76
                                                        154
print("Accuracy Score =", format(metrics.accuracy_score(y_test, svc_pred)))
     Accuracy Score = 0.7662337662337663
#decision tree
dtree = DecisionTreeClassifier()
dtree.fit(X_train, y_train)
predictions = dtree.predict(X_test)
print(confusion_matrix(y_test, predictions))
print(classification_report(y_test, predictions))
     [[80 19]
      [16 39]]
                   precision
                               recall f1-score
                                                   support
                0
                        0.83
                                  0.81
                                             0.82
                                                         99
                1
                        0.67
                                  0.71
                                            0.69
                                                         55
                                             0.77
                                                        154
         accuracy
                        0.75
                                  9.76
        macro avg
                                             9.76
                                                        154
     weighted avg
                        0.78
                                  0.77
                                            0.77
                                                        154
```

Grid Search

```
param_grid = {'C' : [0.1, 1], 'gamma':[1, 0.1], 'kernel':['rbf']}
grid = GridSearchCV(SVC(), param_grid, refit=True, verbose=1)
{\tt grid.fit}({\tt X\_train,\ y\_train})
     Fitting 5 folds for each of 4 candidates, totalling 20 fits
     GridSearchCV(estimator=SVC(),
                  param_grid={'C': [0.1, 1], 'gamma': [1, 0.1], 'kernel': ['rbf']},
                  verbose=1)
grid.best_params_
     {'C': 0.1, 'gamma': 1, 'kernel': 'rbf'}
grid.best_estimator_
     SVC(C=0.1, gamma=1)
grid_pred = grid.predict(X_test)
print(confusion_matrix(y_test, grid_pred))
nrint/classification remont(v test grid nred))
```

[[99 0] [55 0]] precision recall f1-score support 0 0.64 1.00 0.78 99 1 0.00 0.00 0.00 55 154 0.64 accuracy 0.32 0.50 0.39 154 macro avg 0.41 0.50 weighted avg 0.64 154

Model dari Best Learner memiliki akurasi 0.64 (64%). Precision yang menunjukkan ketepatan pengklasifikasian menunjukkan bahwa ketepatan pengklasifikasian orang yang tidak terkena diabetes mencapai 64%. Recall yang menunjukkan kelengkapan pengklasifikasian juga menujukkan bahwa kelengkapan dari klasifikasi orang yang tidak terkena diabetes lebih tinggi daripada yang terkena diabetes, yaitu 100%.

KNN

```
knn = KNeighborsClassifier()
knnModel = knn.fit(X_train, y_train)
knnPred = knn.predict(X_test)
print(classification_report(y_test, knnPred))
                   precision
                                recall f1-score
                0
                        0.75
                                   0.71
                                             0.73
                                                         99
                        0.52
                                  0.58
                                             0.55
                                                         55
                                             0.66
                                                        154
         accuracy
                        9.64
                                  9.64
        macro avg
                                             9.64
                                                        154
     weighted avg
                        0.67
                                   0.66
                                             0.67
                                                        154
```

Model dari KNN memiliki akurasi 0.66 (66%). Precision yang menunjukkan ketepatan pengklasifikasian menunjukkan bahwa ketepatan pengklasifikasian orang yang tidak terkena diabetes mencapai 75%. Recall yang menunjukkan kelengkapan pengklasifikasian juga menujukkan bahwa kelengkapan dari klasifikasi orang yang tidak terkena diabetes lebih tinggi daripada yang terkena diabetes, yaitu 71%.

Voting Classifier

```
estimators=[('svm', svc_model),('KNN', knn),('DecisionTree', dtree)]
ensemble = VotingClassifier(estimators, voting='hard')
ensembleModel = ensemble.fit(X_train, y_train)
ensemblePred = ensemble.predict(X test)
print(classification_report(y_test, ensemblePred))
                   precision
                                recall f1-score
                                                   support
                                  0.79
                                             0.79
                0
                        0.80
                                            0.63
                                                         55
                1
                        0.62
                                  0.64
         accuracy
                                             0.73
                                                        154
        macro avg
                        a 71
                                  0 71
                                             0.71
                                                        154
     weighted avg
                        0.73
                                  0.73
                                             0.73
                                                        154
```

Model dari Voting Classifier memiliki akurasi 0.73 (73%). Precision yang menunjukkan ketepatan pengklasifikasian menunjukkan bahwa ketepatan pengklasifikasian orang yang tidak terkena diabetes mencapai 80%. Recall yang menunjukkan kelengkapan pengklasifikasian juga menujukkan bahwa kelengkapan dari klasifikasi orang yang tidak terkena diabetes lebih tinggi daripada yang terkena diabetes, yaitu 79%.

Bagging Classifier (Random Forest)

```
param_dist = {'max_depth' : [2, 3, 4],
              'bootstrap' : [True, False],
              'max_features' : ['auto', 'sqrt', 'log2', None],
              'criterion' : ['gini', 'entropy']}
rfPred = cv_rf.predict(X_test)
print(classification_report(y_test, rfPred))
                   precision
                               recall f1-score
                                                   support
                0
                        0.80
                                  0.88
                                            0.84
                                                        99
                1
                                  0.60
                                                        55
                        0.73
                                            0.66
                                            0.78
                                                       154
         accuracy
                                  0.74
                        0.77
                                            0.75
                                                       154
        macro avg
                        0.78
                                  0.78
                                            0.77
                                                       154
     weighted avg
```

Model dari Bagging Classifier memiliki akurasi 0.78 (78%). Precision yang menunjukkan ketepatan pengklasifikasian menunjukkan bahwa ketepatan pengklasifikasian orang yang tidak terkena diabetes mencapai 80%. Recall yang menunjukkan kelengkapan pengklasifikasian juga menujukkan bahwa kelengkapan dari klasifikasi orang yang tidak terkena diabetes lebih tinggi daripada yang terkena diabetes, yaitu 88%.

Boosting Classifier

```
adaBoost = AdaBoostClassifier()
abModel = adaBoost.fit(X_train, y_train)
abPred = adaBoost.predict(X_test)
print(classification_report(y_test, abPred))
```

	precision	recall	f1-score	support
0 1	0.80 0.62	0.79 0.64	0.79 0.63	99 55
accuracy macro avg weighted avg	0.71 0.73	0.71 0.73	0.73 0.71 0.73	154 154 154

Model dari Boosting Classifier memiliki akurasi 0.73 (73%). Precision yang menunjukkan ketepatan pengklasifikasian menunjukkan bahwa ketepatan pengklasifikasian orang yang tidak terkena diabetes mencapai 80%. Recall yang menunjukkan kelengkapan pengklasifikasian juga menujukkan bahwa kelengkapan dari klasifikasi orang yang tidak terkena diabetes lebih tinggi daripada yang terkena diabetes, yaitu 79%.

CONCLUSION

Berdasarkan akurasinya, di antara model dari best learner, voting classifier, bagging classifier, dan boosting classifier, model terbaik adalah model bagging classifier dengan accuracy 78%.

Produk berbayar Colab - Batalkan kontrak di sini